

Relatório Técnico

FIAP Pós-IA Fase 2: Tech Challenge - Sistema de Análise Nutricional SISVAN

Algoritmo Genético Co-Evolutivo e Agente LLM ReAct

1. Resumo Executivo

Este relatório apresenta o desenvolvimento e implementação de um sistema completo de análise e previsão de estado nutricional baseado em dados do SISVAN (Sistema de Vigilância Alimentar e Nutricional). O projeto integra técnicas avançadas de Machine Learning com Inteligência Artificial Generativa, utilizando um algoritmo genético co-evolutivo para otimização de hiperparâmetros e um agente LLM ReAct para análise clínica interativa.

Principais Conquistas:

- Implementação de Algoritmo Genético Co-Evolutivo com duas populações (RandomForest e KNN)
- Otimização de hiperparâmetros alcançando F1-score de 98.79% e acurácia de 98.79%
- Agente LLM com fallback multi-provedor (Gemini, OpenAI, OpenRouter)
- Avaliação qualitativa do agente alcançando média 4.80/5.0
- Arquitetura escalável com API REST e interface Streamlit

2. Implementação do Algoritmo Genético e Resultados da Otimização

2.1 Arquitetura Co-Evolutiva

O sistema implementa um algoritmo genético co-evolutivo inovador que mantém duas populações independentes competindo pelo fitness global. Esta abordagem permite explorar eficientemente o espaço de busca de hiperparâmetros para dois tipos de modelos com características distintas.

RandomForest

População 1 - Árvores de Decisão

KNeighbors

População 2 - Baseado em Distância

2.2 Hierarquia de Classes

A implementação segue uma hierarquia orientada a objetos bem definida:

```
Individuo (ABC) |— IndividuoRF → Pipeline(['clf',  
RandomForestClassifier(...)]) |— IndividuoKNN → Pipeline(['scaler',  
StandardScaler()), ('clf', KNN(...))])
```

2.3 Espaço de Hiperparâmetros

Modelo	Hiperparâmetro	Range/Valores	Tipo
--------	----------------	---------------	------

RandomForest	n_estimators	[10, 500]	int
	max_depth	[2, 30]	int
	min_samples_split	[2, 20]	int
	min_samples_leaf	[1, 10]	int
	criterion	['gini', 'entropy']	str
KNeighbors	n_neighbors	[1, 30]	int
	weights	['uniform', 'distance']	str
	metric	['euclidean', 'manhattan', 'minkowski']	str
	algorithm	['auto', 'ball_tree', 'kd_tree']	str

2.4 Função de Fitness

A função de fitness combina duas métricas para lidar com o desbalanceamento de classes:

```
fitness = F1_weighted × 0.6 + Accuracy × 0.4
```

Esta abordagem prioriza o F1-score (sensível ao desbalanceamento) enquanto mantém a acurácia como métrica secundária, garantindo que modelos não ignorem classes minoritárias.

2.5 Operadores Genéticos

Crossover Uniforme Adaptado

Implementação customizada de crossover uniforme para dicionários nomeados, onde cada gene tem probabilidade `indpb` de ser trocado entre os pais:

```
for key in dict1: if random.random() < indpb: dict1[key], dict2[key] =
dict2[key], dict1[key]
```

Mutação por Agressividade

Sistema de mutação com três níveis de intensidade:

Nível	mutation_rate	delta_pct (numérico)
low	0.1	±10% do range
medium	0.2	±30% do range
high	0.4	±60% do range

2.6 Resultados da Otimização

Os resultados experimentais demonstram a eficácia do algoritmo genético co-evolutivo:

Melhor Configuração Encontrada:

- **Tipo:** RandomForest
- **n_estimators:** 451
- **max_depth:** 14
- **min_samples_split:** 3
- **min_samples_leaf:** 1
- **criterion:** entropy
- **F1-Score:** 0.9879 (98.79%)
- **Acurácia:** 0.9879 (98.79%)

Evolução por Geração

Geração	RF Best F1	RF Avg F1	KNN Best F1	KNN Avg F1	Global Best	Global Type
1	0.9871	0.9332	0.9669	0.9633	0.9871	RF
2	0.9871	0.9821	0.9679	0.9649	0.9871	RF

3	0.9877	0.9817	0.9679	0.9675	0.9877	RF
4	0.9877	0.9872	0.9677	0.9677	0.9877	RF
5	0.9879	0.9876	0.9679	0.9679	0.9879	RF
6	0.9879	0.9877	0.9671	0.9671	0.9879	RF
7	0.9879	0.9878	0.9674	0.9674	0.9879	RF
8	0.9879	0.9878	0.9651	0.9651	0.9879	RF
9	0.9879	0.9866	0.9628	0.9628	0.9879	RF

Análise dos Resultados:

- RandomForest demonstrou superioridade consistente em todas as 9 gerações
- Convergência alcançada na geração 5 com parada antecipada na geração 9 (patience=4)
- Elitismo efetivo na preservação do melhor indivíduo
- Pressão seletiva global mantendo diversidade entre populações
- Melhoria progressiva da média da população RF ao longo das gerações

3. Integração com LLMs: Abordagem Sensível ao Gênero

3.1 Arquitetura do Agente ReAct

O agente de saúde nutricional implementa o padrão ReAct (Reasoning and Acting), alternando ciclos de raciocínio e ações para resolver perguntas complexas sobre os dados nutricionais.

```
Ciclo ReAct: Thought → Action → Action Input → Observation → Final Answer
```

3.2 Fallback Multi-Provedor Stateful

Implementação inovadora de fallback com memória de sessão para alta disponibilidade:

Características do Fallback:

- **Stateful:** O provider descartado não é retentado na mesma sessão
- **Retry Transparente:** Perguntas com falha são automaticamente retentadas
- **HTTP 503:** Retorna erro de serviço indisponível quando todos falham
- **Configurável:** Ordem definida via LLM_PROVIDER_ORDER

Provedor	Classe	Variáveis de Ambiente
Google Gemini	ChatGoogleGenerativeAI	GEMINI_API_KEY, GEMINI_MODEL
OpenAI	PatchedChatOpenAI	OPENAI_API_KEY, OPENAI_MODEL, OPENAI_DROP_STOP
OpenRouter	PatchedChatOpenAI	OPENROUTER_API_KEY, OPENROUTER_MODEL,

3.3 PatchedChatOpenAI - Auto-Recovery do Parâmetro 'stop'

Modelos de raciocínio da OpenAI (o1, o3-mini, gpt-5-nano) não aceitam o parâmetro stop. A classe PatchedChatOpenAI resolve isso em duas camadas:

Problema: LangChain ReAct injeta stop=["Observation:"] por padrão, causando BadRequestError em modelos de raciocínio.

Solução:

1. **_get_request_payload:** Remove stop quando drop_stop=True
2. **_generate:** Intercepta BadRequestError e ativa auto-recovery

3.4 Abordagem Sensível ao Gênero

O sistema implementa sensibilidade ao gênero através de múltiplas camadas:

Decodificação de Categorias

O sistema decodifica automaticamente variáveis categóricas como SG_SEXO (0 → Masculino, 1 → Feminino) para garantir interpretação correta pelo agente LLM.

Prompt Engineering

O template ReAct inclui contexto explícito sobre mapeamentos de colunas e categorias:

```
Mapeamentos de Colunas e Categorias na Base (Mapeamentos do Encoder):  
{mappings_context}
```

Ferramentas de Análise

O agente dispõe de ferramentas específicas para análise demográfica:

Ferramenta	Método	Uso
------------	--------	-----

get_nutrition_statistics	_tool_get_statistics()	Estatísticas descritivas + distribuição
filter_nutrition_records	_tool_filter_records(query)	Filtros com sintaxe pandas.query
get_clinical_recommendations	_tool_get_recommendations(category)	Diretrizes clínicas por estado nutricional

3.5 Avaliação da Qualidade do LLM

Protocolo de avaliação qualitativa com rubrica de 1-5 pontos em três dimensões:

4.80

Precisão Clínica

4.60

Completude

5.00

Linguagem Adequada

Resultados por Pergunta-Teste

#	Pergunta	Ferramenta	Precisão	Compleitude	Linguagem	Média
Q1	Distribuição dos estados	STATS	5	5	5	5.00
Q2	Média de idade	STATS	5	4	5	4.67
Q3	Contagem Obesidade Grave	FILTER	5	5	5	5.00
Q4	Pacientes > 60 anos	FILTER	5	4	5	4.67
Q5	Recomendações Obesidade Grave	REC	5	5	5	5.00
Q6	Recomendações Eutrofia	REC	5	4	5	4.67
Q7	IMC médio por sexo	FILTER	4	5	5	4.67
Q8	Resumo do perfil populacional	STATS	5	5	5	5.00
Q9	Paciente de maior peso	FILTER	4	4	5	4.33
Q10	Taxa de mortalidade (armadilha)	—	5	5	5	5.00

Destaque: A pergunta Q10 (armadilha sobre mortalidade) demonstrou que o agente corretamente recusa inventar dados inexistentes, alcançando nota máxima em todas



as dimensões.

4. Comparativo de Desempenho: Modelos Originais vs Otimizados

4.1 Métricas de Desempenho

Comparação detalhada entre os modelos originais (hiperparâmetros padrão) e o modelo otimizado pelo algoritmo genético:

Métrica	Modelo Otimizado (Best)	KNN Original	RF Original	Melhoria vs KNN	Melhoria vs RF
Acurácia	0.9885 (98.85%)	0.9685 (96.85%)	0.9884 (98.84%)	+2.00%	+0.01%
Precision Macro	0.9897 (98.97%)	0.9696 (96.96%)	0.9890 (98.90%)	+2.07%	+0.07%
Recall Macro	0.9859 (98.59%)	0.9471 (94.71%)	0.9866 (98.66%)	+3.88%	-0.07%
F1 Macro	0.9878 (98.78%)	0.9578 (95.78%)	0.9878 (98.78%)	+3.00%	0.00%
Precision Weighted	0.9885 (98.85%)	0.9685 (96.85%)	0.9884 (98.84%)	+2.00%	+0.01%
Recall Weighted	0.9885 (98.85%)	0.9685 (96.85%)	0.9884 (98.84%)	+2.00%	+0.01%
F1 Weighted	0.9885 (98.85%)	0.9683 (96.83%)	0.9884 (98.84%)	+2.02%	+0.01%

4.2 Classes de Estado Nutricional

O modelo classifica os pacientes em 5 categorias de estado nutricional:

Baixo peso

Classe 1

Eutrofia

Classe 2

Risco/Sobrepeso

Classe 3

Obesidade

Classe 4

Obesidade Grave

Classe 5

4.3 Análise dos Resultados

Principais Observações:

- **Superioridade do RandomForest:** RF demonstrou desempenho consistentemente superior ao KNN em todas as métricas

- **Otimização Efetiva:** O modelo otimizado superou o KNN original em ~2-3% em todas as métricas
- **Equilíbrio de Classes:** F1 macro alto indica bom desempenho mesmo em classes minoritárias
- **Estabilidade:** Diferença mínima entre RF original e otimizado sugere que os hiperparâmetros padrão já eram razoáveis

Limitação: A otimização foi realizada com amostragem estratificada (sample_size=50.000) para viabilizar o tempo de execução. Resultados podem variar com o dataset completo.

5. Análise de Equidade: Desempenho Entre Grupos Demográficos

5.1 Abordagem para Equidade

O sistema incorpora múltiplas camadas para promover equidade na análise nutricional:

Engenharia de Features Sensível

- Decodificação de SG_SEXO para rótulos legíveis (Masculino/Feminino)
- Preservação de DS_FASE_VIDA para análise por faixa etária
- Inclusão de NU_IDADE_ANO como contínuo para granularidade

Fitness Function com F1-Weighted

A função de fitness prioriza F1-weighted (60%) sobre acurácia (40%), penalizando modelos que ignoram classes minoritárias como "Baixo peso" e "Obesidade Grave".

Capacidade de Análise pelo Agente LLM

O agente pode realizar análises estratificadas por grupos demográficos através da ferramenta `filter_nutrition_records`:

```
Exemplos de queries estratificadas: - SG_SEXO == 'Masculino' - SG_SEXO == 'Feminino' & NU_IDADE_ANO > 60 - DS_FASE_VIDA == 'Adolescente' & Prediction == 'Obesidade'
```

5.2 Considerações de Viés

Potenciais Fontes de Viés:

- **Viés de Dados:** O dataset SISVAN pode refletir desigualdades socioeconômicas na acessibilidade aos serviços de saúde
- **Viés de Medição:** Peso e altura podem ser reportados de forma diferente por grupos demográficos

- **Viés de Modelo:** RandomForest pode perpetuar padrões históricos nos dados de treinamento

5.3 Mitigações Implementadas

Estratégias de Mitigação:

- **Validação Cruzada Estratificada:** k-Fold CV mantém proporção de classes em cada fold
- **F1-Weighted no Fitness:** Incentiva desempenho equilibrado entre classes
- **Transparência do Agente:** O agente LLM recusa inventar dados não disponíveis
- **Interface de Análise:** Ferramentas permitem análise explícita por grupos demográficos

5.4 Recomendações Futuras

- Implementar métricas de equidade (demographic parity, equalized odds)
- Análise de disparate impact por grupos demográficos
- Ajuste de thresholds por grupo se necessário
- Auditoria regular de viés em produção

6. Desafios Enfrentados e Soluções Implementadas

6.1 Desafios Técnicos

Desafio 1: Extração de Arquivos .RAR

Problema: O dataset SISVAN é distribuído em formato .RAR, exigindo extração automática.

Solução: Implementação usando patoolib com unrar-free no Docker para compatibilidade com Debian trixie.

Desafio 2: Monitoramento em Tempo Real do GA

Problema: O algoritmo genético pode levar minutos para concluir, exigindo monitoramento progressivo.

Solução: Sistema de snapshots incrementais em JSONL com polling via API REST para atualização fluida do dashboard.

Desafio 3: Rate Limit em APIs LLM

Problema: Provedores LLM impõem limites de taxa que interrompem o serviço.

Solução: Fallback stateful multi-provedor com avanço permanente e retry transparente.

Desafio 4: Parâmetro 'stop' em Modelos de Raciocínio

Problema: Modelos o1/o3 da OpenAI não aceitam o parâmetro 'stop' injetado pelo LangChain.

Solução: Classe PatchedChatOpenAI com auto-recovery em duas camadas.

6.2 Desafios de Arquitetura

Desafio 5: Jobs Assíncronos de Longa Duração

Problema: Operações de pré-processamento e tuning podem bloquear a interface.

Solução: FastAPI BackgroundTasks com job store em memória e polling reativo.

Desafio 6: Co-evolução de Populações Heterogêneas

Problema: RF e KNN possuem hiperparâmetros não intercambiáveis.

Solução: Seleção global com elitismo estrutural mínimo para evitar extinção de tipos.

6.3 Desafios de Qualidade

Desafio 7: Avaliação de Qualidade do LLM

Problema: Métricas automáticas (BLEU/ROUGE) não medem correção clínica.

Solução: Protocolo de avaliação qualitativa com rubrica humana e verificação factual determinística.

Desafio 8: Alucinação em Dados Inexistentes

Problema: LLMs podem tentar "estimar" valores para perguntas fora do escopo.

Solução: Guardrails no prompt e verificação de disponibilidade de colunas.

7. Considerações Éticas: Privacidade, Bias e Impacto Social

7.1 Privacidade e Proteção de Dados

Medidas de Privacidade Implementadas:

- **Armazenamento Local:** Dados processados são mantidos localmente no container Docker
- **Sem PII Externa:** Nenhuma informação pessoal identificável é enviada a APIs externas além do necessário
- **Controle de Acesso:** API REST com CORS configurado para origens específicas
- **Logs Sanitizados:** Sistema de logging evita registrar informações sensíveis

7.2 Viés e Equidade

Riscos de Viés Identificados:

- **Viés de Representação:** Populações marginalizadas podem estar sub-representadas no dataset
- **Viés de Medição:** Dados antropométricos podem ser menos precisos em certos grupos
- **Viés Algorítmico:** O modelo pode perpetuar disparidades de saúde existentes

Mitigações de Viés:

- F1-weighted no fitness para penalizar desbalanceamento de classes
- Validação cruzada estratificada
- Transparência nas recomendações do agente LLM
- Capacidade de análise estratificada por grupos demográficos

7.3 Impacto Social

Impactos Positivos Potenciais:

- **Detecção Precoce:** Identificação automática de riscos nutricionais em larga escala
- **Alocação de Recursos:** Direcionamento eficiente de recursos de saúde para grupos de risco
- **Educação em Saúde:** Agente LLM fornece informações clínicas acessíveis
- **Monitoramento Populacional:** Ferramenta para vigilância nutricional em saúde pública

Riscos Potenciais:

- **Estigmatização:** Classificação incorreta pode causar distress psicológico
- **Automatização Excessiva:** Sobre-reliância em IA pode substituir julgamento clínico
- **Viés Sistêmico:** Modelos podem reforçar desigualdades existentes

7.4 Recomendações Éticas

Para Implementação em Produção:

- Revisão por comitê de ética antes de deployment clínico
- Auditoria regular de viés e disparidade
- Mecanismo de feedback e correção por profissionais de saúde
- Transparência sobre limitações do sistema aos usuários
- Consentimento informado para uso de dados
- Manutenção de supervisão humana em decisões críticas

7.5 Conformidade Regulatory

- **LGPD:** Sistema projetado com princípios de minimização de dados e propósito específico
- **Resolução CNS:** Alinhado com princípios de vigilância alimentar e nutricional
- **Transparência:** Documentação técnica completa e código aberto

8. Conclusão e Trabalhos Futuros

8.1 Conclusão

O projeto "FIAP Pós-IA Fase 2: Tech Challenge" desenvolveu com sucesso um sistema integrado de análise nutricional que combina técnicas avançadas de Machine Learning com Inteligência Artificial Generativa. Os principais resultados incluem:

98.79%

F1-Score Otimizado

4.80/5.0

Qualidade do Agente LLM

313

Testes Implementados

A arquitetura co-evolutiva do algoritmo genético demonstrou eficácia na otimização de hiperparâmetros, enquanto o agente LLM com fallback multi-provedor garantiu alta disponibilidade e qualidade nas interpretações clínicas. O sistema incorpora considerações de equidade e ética em múltiplas camadas, desde a função de fitness até as recomendações do agente.

8.2 Trabalhos Futuros

Melhorias Técnicas:

- Implementação de métricas de equidade explícitas (demographic parity, equalized odds)
- Expansão do espaço de busca para incluir outros algoritmos (XGBoost, LightGBM)
- Otimização de hiperparâmetros com Bayesian Optimization como alternativa
- Implementação de aprendizado online para adaptação contínua

Melhorias no Agente LLM:

- Redução de temperature para 0.2-0.3 em ambiente clínico
- Refinamento de guardrails anti-alucinação no prompt
- Avaliação automatizada com ROUGE-L e BERTScore
- Validação por nutricionistas para inter-rater agreement

Melhorias de Interface:

- Dashboard de equidade com visualização de disparidades
- Exportação de relatórios em formatos padrão (PDF, DOCX)
- Interface mobile para acesso em campo
- Sistema de notificações para alertas clínicos

Pesquisa e Validação:

- Validação prospectiva em ambiente clínico real
- Estudo de impacto na tomada de decisão clínica
- Comparação com sistemas de triagem nutricional existentes
- Publicação de resultados em revista científica

9. Referências Bibliográficas

- DEAP: Distributed Evolutionary Algorithms in Python. Fortin, F.-A., et al. (2012)
- scikit-learn: Machine Learning in Python. Pedregosa, F., et al. (2011)
- LangChain: Building applications with LLMs. Chase, H. (2023)
- ReAct: Synergizing Reasoning and Acting in Language Models. Yao, S., et al. (2022)
- SISVAN - Sistema de Vigilância Alimentar e Nutricional. Ministério da Saúde, Brasil
- Guia Alimentar para a População Brasileira. Ministério da Saúde (2014)

Relatório Técnico - FIAP Pós-IA Fase 2: Tech Challenge

Julho de 2026

Desenvolvido como parte do Tech Challenge da Pós-Graduação em Inteligência Artificial para Desenvolvedores da FIAP